

Cours Statistique Bayésienne

Dhafer Malouche

3ième année ESSAI, 2015-2016

- Introduction au calcul Bayésien
 - Théorème de Bayes
 - Exercice
 - Solution avec \mathbb{R}
 - Solution théorique
- Le modèle Bayésien et théorie de la décision
 - Notions de la théorie de décision.
 - Exemples : $\Theta = \mathcal{E} = \mathbb{R}$
 - Le cas bayésien.
 - Risque Bayésien
 - Estimateur Bayésien
- Le choix de la loi a priori
 - Lois a priori conjuguées.
 - Lois a priori de Jeffrey.
- Modèle Bernoulli

Introduction au calcul Bayésien

(Séance 1, 3/9/2016)

Théorème de Bayes

Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace de probabilité. Soient X et Y deux évènements de \mathcal{A} . Alors

$$\mathbb{P}(X | Y) = \frac{\mathbb{P}(X \cap Y)}{\mathbb{P}(Y)}$$

Exercice

On considère un test pour une infection. On suppose que la sensibilité du test est égale à 99% (la probabilité qu'un infecté soit détecté positif) et que la spécificité du test est égale à 97% (la probabilité qu'une personne saine soit détectée négative). Sachant que la proportion des personnes infectées dans une population est égale à 1%.

- Question 1 Quelle est la probabilité qu'une personne ayant eu un résultat positif au test soit détectée infectée.
- Question 2 Cette personne passe ce test une deuxième fois et il est encore positif. Quelle est la probabilité qu'elle soit infectée.

Solution avec R

Question 1

- On simule une population avec un taux d'infection égal à 1%.

```
> N=10000 # Taille de la population
> p=0.01 # Probabilité d'infection
> population=rbinom(N,1,prob = p)
> N_infected=sum((population==1));N_infected ## Nombre d'infectés
[1] 97
> infected=which(population==1)
```

- On simule le test

```
> sensitivity=.99
> specificity=.97
> test=rbinom(N,1,(population==1)*sensitivity+(population==0)*(1-specificity))
> N_test=sum((test==1));N_test ## Nombre de positifs.
[1] 380
```

- La matrice de confusion test x population

```
> confusion=xtabs(~population+test);confusion
      test
population  0    1
      0 9620  283
      1    0   97
```

Donc la probabilité qu'une personne ayant eu un résultat positif au test soit détectée infectée se calcule de la façon suivante

```
> confusion[2,2]/(confusion[1,2]+confusion[2,2])
[1] 0.2552632
```

Question 2

- Simulant une deuxième fois le test

```
> test2=rbinom(N,1,(population==1)*sensitivity+(population==0)*(1-specificity))
```

- Considérons le croisement entre les trois variables population, test et test2

```
> confusion2=xtabs(~population+test2+test);confusion2
, , test = 0

      test2
population 0    1
0  9329  291
1     0    0

, , test = 1

      test2
population 0    1
0   271   12
1     0   97
```

- Donc la probabilité qu'une personne infectée sachant qu'elle a réagit positivement deux fois au test est

```
> confusion2[2,2,2]/(confusion2[2,2,2]+confusion2[2,1,2])
[1] 1
```

Solution théorique

On note par M l'événement qu'une personne soit infectée et par P qu'elle soit détectée positive. Alors

$$\text{sensitivité} = \mathbb{P}(P | M) = \frac{\mathbb{P}(P \cap M)}{\mathbb{P}(M)} = .99$$

et

$$\text{spécificité} = \mathbb{P}(\bar{P} | \bar{M}) = \frac{\mathbb{P}(\bar{P} \cap \bar{M})}{\mathbb{P}(\bar{M})} = .97$$

Donc la la probabilité qu'une personne ayant eu un résultat positif au test soit détectée infectée se calcule

$$\mathbb{P}(M | P) = \frac{\mathbb{P}(P \cap M)}{\mathbb{P}(P)} = \frac{\mathbb{P}(P | M)\mathbb{P}(M)}{\mathbb{P}(P | \bar{M})\mathbb{P}(\bar{M}) + \mathbb{P}(P | M)\mathbb{P}(M)} = \frac{.99 \times .01}{(1 - .97) \times (1 - .01) + .99 \times .01} = 0.25$$

Le modèle Bayésien et théorie de la décision

(Séance 2, 10/9/2015)

Notions de la théorie de décision.

Soit \mathcal{M} un modèle paramétrique : Soit $\underline{X} = (X_1, \dots, X_n)$ un n -échantillon de loi \mathbb{P} dépendant d'un paramètre $\theta \in \Theta \subseteq \mathbb{R}^p$.

- Rappelons un estimateur de θ est une fonction du n-échantillon \underline{X} :

$$\hat{\theta}(\underline{X}) \in \mathcal{E} \supseteq \Theta$$

- Comment évaluer la qualité d'un estimateur $\hat{\theta}$?
- Fonction de Perte :

$$L : \Theta \times \mathcal{E} \longrightarrow \mathbb{R}^+$$

telle que $L(\theta, \theta) = 0$ pour tout $\theta \in \Theta$. Donc l'erreur de l'estimation de $\hat{\theta}$ est mesurée par $L(\theta, \hat{\theta})$.

- Fonction de Risque

$$\theta \longmapsto R(\theta, \hat{\theta}) = \mathbb{E} [L(\theta, \hat{\theta})]$$

Exemples : $\Theta = \mathcal{E} = \mathbb{R}$

Perte quadratique

$L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$ et le risque associée est le risque quadratique

$$R(\theta, \hat{\theta}) = \mathbb{E} [(\theta - \hat{\theta})^2]$$

Perte absolue

$L(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$ et le risque associée est le risque quadratique

$$R(\theta, \hat{\theta}) = \mathbb{E} [|\theta - \hat{\theta}|]$$

Intuitivement plus le risque de l'estimateur est faible plus l'estimateur $\hat{\theta}$ est considéré comme performant.

Exercice

Soit $\underline{X} = (X_1, \dots, X_n)$ telle que pour tout $i = 1, \dots, n$, $X_i \sim \mathcal{N}(\theta, 1)$. On considère \bar{X} comme estimateur de θ . Calculer le risque quadratique de \bar{X} .

Le cas bayésien.

Risque Bayésien

Dans le cas bayésien on suppose qu'on dispose d'une certaine information a priori sur le paramètre θ qu'on la traduit avec une distribution de probabilité π notée $\pi(\cdot)$.

Notre objectif est de mettre à jour cette information une fois qu'on a observé l'échantillon des données.

Si on suppose que $\underline{X} = (X_1, \dots, X_n)$ est issu d'une loi de probabilité de densité $f(x|\theta)$. Alors la fonction vraisemblance

$$L(\theta, \underline{x}) = \prod_{i=1}^n f(x_i | \theta)$$

On calcule alors ce qu'on appelle la loi a posteriori de θ :

$$\pi(\theta | \underline{x}) \propto L(\theta, \underline{x}) \pi(\theta)$$

Exemples

Calculer la loi a posteriori dans les cas suivants

1. f est la loi Bernoulli(θ) et $\theta \sim \text{Beta}(a, b)$.
2. f est la loi $\mathcal{N}(\theta, 1)$ et $\theta \sim \mathcal{N}(0, 1)$.
- **Risque Bayésien** On considère une fonction $L(\cdot; \cdot)$ et modèle statistique paramétrique $\mathcal{M} = \{\mathcal{X}, \mathcal{A}, \mathbb{P}, \theta \in \Theta\}$. On considère une loi a priori π sur le paramètre θ . Le risque bayésien d'une estimateur $\hat{\theta}(\underline{x})$

$$\mathcal{R}(\hat{\theta}(\underline{x})) = \int_{\Theta} \mathcal{R}(\theta, \hat{\theta}(\underline{x})) \pi(d\theta)$$

Estimateur Bayésien

- L'estimateur $\hat{\theta}^B(\underline{x})$ est appelé estimateur de Bayes associé à la fonction de perte L et à l'a priori π c'est l'estimateur qui minimise le risque bayésien

$$\mathcal{R}(\hat{\theta}^B(\underline{x})) = \min_{\hat{\theta}(\underline{x}) \in \mathcal{E}} \mathcal{R}(\hat{\theta}(\underline{x}))$$

- **Remarque :** L'expression de l'estimateur bayésien dépend du choix de la loi a priori π et de la fonction perte L .
- **Théorème :** Supposons que
 1. Il existe un estimateur $\hat{\theta}_0(\underline{x})$ tel que $\mathcal{R}(\hat{\theta}_0(\underline{x})) < \infty$.
 2. Pour presque tout $x \in \mathcal{X}$ il existe

$$\hat{\theta}(\underline{x}) = \operatorname{argmin}_{y \in \mathcal{E}} \mathbb{E}[L(\theta, y) | X = x]$$

3. La fonction $x \rightarrow \hat{\theta}(\underline{x})$ est mesurable.

Alors

$$\hat{\theta}(\underline{x}) = \hat{\theta}^B(\underline{x})$$

- **Corollaire** Considérons le cas $\Theta = \mathcal{E} = \mathbb{R}$
 1. Si $L(\theta, \theta') = (\theta - \theta')^2$ est la fonction perte quadratique, alors l'estimateur bayésien est donné par la moyenne a posteriori

$$\hat{\theta}^B(\underline{x}) = \mathbb{E}(\theta | X)$$

De plus $\hat{\theta}^B(\underline{X}) = \mathbb{E}[\theta \mid \underline{X}]$

2. Si $L(\theta, \theta') = |\theta - \theta'|$, alors l'estimateur bayésien est donné par la médiane a posteriori

$$\hat{\theta}^B(\underline{X}) = \text{Médiane}_{|\underline{X}}$$

- Théorème Si un estimateur bayésien est sans biais alors il a un risque bayésien nul.

Exercice

Soit $X = (X_1, \dots, X_n)$ un échantillon i.i.d de loi normale de moyenne θ inconnue et de variance σ^2 .
 Considérons la loi a priori $\pi = \mathcal{N}(0, \frac{1}{\sigma_0^2})$. 1. Calculer la loi a posteriori sur θ . 2. En déduire l'expression de l'estimateur bayésien associé à la fonction perte quadratique. 3. Calculer le risque bayésien de l'estimateur bayésien. 4. Répondre aux questions 1,2,3 avec la fonction perte $L(\theta, \theta') = (\theta - \theta')^2 \exp(\theta^2)$. On considérera le cas où $\sigma^2 = 1$.

Le choix de la loi *a priori*

(Séance 3, 17/9/2016)

Pour construire une loi a priori on doit distinguer 3 cas possibles :

1. On dispose d'une information a priori partielle, donnée par l'expérience.
2. On dispose d'une quantité limitée : lois conjuguées.
3. On dispose d'une quantité limitée ou même aucune information sur θ : la loi a priori de Jeffrey.

Lois *a priori* conjuguées.

Une loi a priori conjuguée sur θ pour un modèle statistique donné si la loi a posteriori sur θ appartient à la même famille de la loi a priori.

Exercice.

Calculer dans les cas suivants la loi a priori conjuguée sur θ et calculer la loi a posteriori :

- $\mathcal{N}(\theta; \sigma^2)$ où σ^2 est connue.
- $\text{Poisson}(\theta)$
- $\Gamma(\theta; \alpha)$ où α est connue.
- $\text{Binomiale}(N, \theta)$
- $\mathcal{N}(\theta; \sigma^2)$ où σ^2 est connue.

Lois *a priori* de Jeffrey.

On suppose que le n-échantillon X_1, \dots, X_n de densité $f(\cdot \mid \theta)$. La loi de Jeffrey se construit à partir seulement la connaissance de la densité $f(\cdot \mid \theta)$. Cette famille de lois est basée sur le calcul de l'information de Fisher :

$$I(\eta) = \mathbb{E} \left[\left(\frac{\partial \log f(X | \eta)}{\partial \eta} \right)^2 \right]$$

Dans le cas de modèles réguliers.

$$I(\eta) = \mathbb{E} \left[\frac{\partial^2 \log f(X | \eta)}{\partial \eta^2} \right] = \mathbb{E} \left[\frac{\partial^2 \log l_n(\eta)}{\partial \eta^2} \right]$$

où l_n est le log-vraisemblance. Ces lois sont souvent des lois a priori non-informatives.

Définition la loi a priori de Jeffrey qu'on note J^η c'est la loi qui admet la densité suivante

- Si $\Theta \subseteq \mathbb{R}$

$$q(\eta) \propto I^{-1/2}(\eta)$$

- Si $\Theta \subseteq \mathbb{R}^d$

$$q(\eta) \propto |I(\eta)|^{-1/2}$$

Exercice

Reprendre les modèles statistiques de l'exercice précédent et calculer les lois a priori de Jeffrey correspondantes.

Exercice

On considère $\underline{x} = (x_1, \dots, x_n)$ un échantillon i.i.d d'une variable X de loi de densité

$$f(x | \eta, \gamma) \propto \exp\left(-\frac{\gamma}{2} x^2 + \eta x\right)$$

définie sur tout \mathbb{R} .

1. Montrer que la loi de X est une loi $\mathcal{N}\left(\frac{\eta}{\gamma}, \frac{1}{\gamma}\right)$
2. En déduire la constante de normalisation de la densité f .
3. Ecrire la fonction vraisemblance $L(\eta, \gamma | \underline{x})$.
4. Supposons que γ est connue.
 - a. En déduire une loi a priori conjuguée pour η
 - b. Calculer la loi a posteriori de η
 - c. Calculer l'estimateur de Bayes de η en considérant la fonction de perte quadratique.
 - d. Reprendre les questions a,b et c. en considérant la loi a priori de Jeffrey.
5. On suppose maintenant que η est connue
 - a. En déduire une loi a priori conjuguée pour γ
 - b. Calculer la loi a posteriori de γ

Exercice

On considère le code suivant

```

> p = seq(0.05, 0.95, by = 0.1)
> prior = c(1, 5.2, 8, 7.2, 4.6, 2.1, 0.7, 0.1, 0, 0)
> prior = prior/sum(prior)
> Likelyhood=function(p,s,f) p^s*(1-p)^f
> Lp=sapply(p,function(x) Likelyhood(x,11,16))
> post=Lp*prior
> post=post/sum(post)
> round(post,4)
[1] 0.0000 0.0023 0.1291 0.4768 0.3338 0.0559 0.0021 0.0000 0.0000 0.0000

```

1. Quel est le modèle Bayésien considéré dans ce code?
2. Calculer l'estimateur bayésien du paramètre considéré dans ce code.
3. Donner une loi a priori conjuguée du modèle Bayésien.

Modèle Bernoulli

- y_1, \dots, y_n un n-échantillon de loi Bernoulli $\mathcal{B}(p)$.
- La loi a priori conjuguée

$$g(p) = \frac{\Gamma(\tilde{\alpha})}{\Gamma(\tilde{\alpha})\Gamma(\tilde{\beta})} \hat{p}^{\tilde{\alpha}-1} (1-\hat{p})^{\tilde{\beta}-1}$$

- De moyenne

$$E(p) = \frac{\hat{p}}{\tilde{\alpha} + \tilde{\beta}}$$

- De Variance


$$\text{Var}(p) = \frac{\hat{p}(1-\hat{p})}{(\tilde{\alpha} + \tilde{\beta})^2(\tilde{\alpha} + \tilde{\beta} + 1)}$$

- De densité

```

> curve(dbeta(x,4,3),from = 0,to = 1,col="red",lwd=2,xlab = "",ylab="")

```

- Calcul d'une loi a priori : On croit que la médiane et 90ième percentile de p sont respectivement égales à 0,3 et 0,5.

```
> library(LearnBayes)
> quantile2=list(p=.9,x=.5)
> quantile1=list(p=.5,x=.3)
> beta.select(quantile1,quantile2)
[1] 3.26 7.19
```

- La loi a posteriori


$$g(p \mid \text{données}) \propto p^{s^f - 1} (1 - p)^{N - s^f - 1}$$

- Représentation des lois a priori, a posteriori et vraisemblance.

```

> a = beta.select(quantile1,quantile2)[1]
> b = beta.select(quantile1,quantile2)[2]
> s = 11
> f = 16
> curve(dbeta(x,a+s,b+f), from=0, to=1,
+ xlab="p",ylab="Density",lty=1,lwd=4)
> curve(dbeta(x,s+1,f+1),add=TRUE,lty=2,lwd=4)
> curve(dbeta(x,a,b),add=TRUE,lty=3,lwd=4)
> legend(.7,4,c("Prior","Likelihood","Posterior"),
+ lty=c(3,2,1),lwd=c(3,3,3))

```



- Calcul de la probabilité $P(p \geq .5 \mid \text{données})$.

```

> 1 - pbeta(0.5,a+s,b+f)
[1] 0.0690226

```

- Estimer une valeur future \tilde{y} (le nombre de fois de la réalisations d'événement de probabilité p quand l'expérience s'est répétée n fois). On calcule la densité prédictive de \tilde{y} :

$$f(\tilde{y}) = \int f(\tilde{y} \mid p)g(p)dp.$$

- Deux type densités prédictives : a priori si g est la loi a priori ou a posteriori si g est la loi a posteriori

Exemple

On lance une pièce de monnaie n fois, on observe y fois piles, on considère une loi a priori sur p . Supposons qu'on veut jeter m fois la pièce et on veut prédire le nombre \tilde{y} d'apparitions de la face Pile.

- Solution fréquentiste : estimer p par $\hat{p} = y/n$, et prédire \tilde{y} par $\tilde{y} = m\hat{p} = my/n$?
- Solution bayésienne : calculer la densité prédictive a posteriori de \tilde{y} .

$$\begin{aligned} g(\tilde{y} | y) &= \int g(\tilde{y}, p | y) dp \\ &= \int g(\tilde{y} | p) g(p | y) dp \end{aligned}$$

La loi Beta-Binomiale

On a déjà vu que si $p \sim \text{Beta}(a, b)$ alors $p | y \sim \text{Beta}(y + a, n - y + b)$. La loi densité prédictive a posteriori s'écrit


$$\begin{aligned} g(\tilde{y} | y) &= \frac{1}{B(y + a, n - y + b)} \int_0^1 C_m^{\tilde{y}} p^{\tilde{y}} (1 - p)^{m - \tilde{y}} p^{y + a} (1 - p)^{n - y + b} dp \\ &= C_m^{\tilde{y}} \frac{B(\tilde{y} + y + a, m - \tilde{y} + n - y + b)}{B(y + a, n - y + b)} \end{aligned}$$

On dit que \tilde{y} suit une loi Beta-Binomiale de paramètres $m, y + a, n - y + b$.

Application

On observe pour $n = 40, y = 13$ et on veut prédire les probabilités d'observer le nombre de Piles après $m = 13$

```
> library(emdbook)
> y=13
> n=40
> ### a priori beta 2,4
> a=2
> b=4
> m=13
> yy=0:m
> ## Calcul de la loi predictive a posteriori.
> predy=sapply(yy,function(x) dbetabinom(x,shape1 = y+a,shape2 = n-y+b,size = m))
> names(predy)=yy
> plot(yy,predy,xlab="y",ylab="loi predictive a posteriori",
+ type="h",lwd=3)
```



Exemple : combien de fois on a jeté un dé

- Supposons qu'on a jeté plusieurs fois une pièce de monnaie équilibrée et on vous dit qu'on a obtenu "face" 13 fois.
- Question : Pourrions-nous estimer le nombre de jets de la pièce ?
- Solution : On considère un a priori non-informative sur n : $g(n) \propto 1$ et la vraisemblance est alors

$$L(n) \propto C_n^{13} \left(\frac{1}{2}\right)^n.$$


Ainsi la loi a posteriori s'exprime

$$g(n | x) \propto L(n)g(n) = C_n^{13} \left(\frac{1}{2}\right)^n.$$

```

> n=13:100
> posteriori=function(n,p) choose(n,13)*p^13*(1-p)^(n-13)
> ### le cas p=.5
> postn=sapply( n,function(n) posteriori(n,.5))
> postn=postn/sum(postn)
> ##### Graphique et comparer avec 2*13=26.
> plot(n,postn,type="h",lwd=.8,col="red",xlab="n",
+ ylab="a posteriori")
> abline(v=26,col="blue",lwd=1.5)

```



- Comparons n avec x/p pour différentes valeurs de p .

```

> p=seq(0.1,0.8,by=0.1)
> par(mfrow=c(2,4))
> for(i in 1:8){
+   postn=c()
+   postn=sapply( n,function(n) posteriori(n,p[i]))
+   postn=postn/sum(postn)
+   plot(n,postn,type="h",lwd=.8,col="red",xlab="n",
+ ylab="a posteriori", main=paste("p=",p[i],sep=""))
+   abline(v=13/p[i],col="blue",lwd=1.5)
+ }

```

